5.10 – Dados no MongoDB

Nesta etapa, trabalharemos com armazenamento, a quarta etapa do pipeline dos dados. O banco de dados que iremos utilizar para realizar essa tarefa será o MongoDB.

1º passo: Criar uma conta no mLab / Configurar

Inicialmente, precisamos criar uma conta no site https://mlab.com/

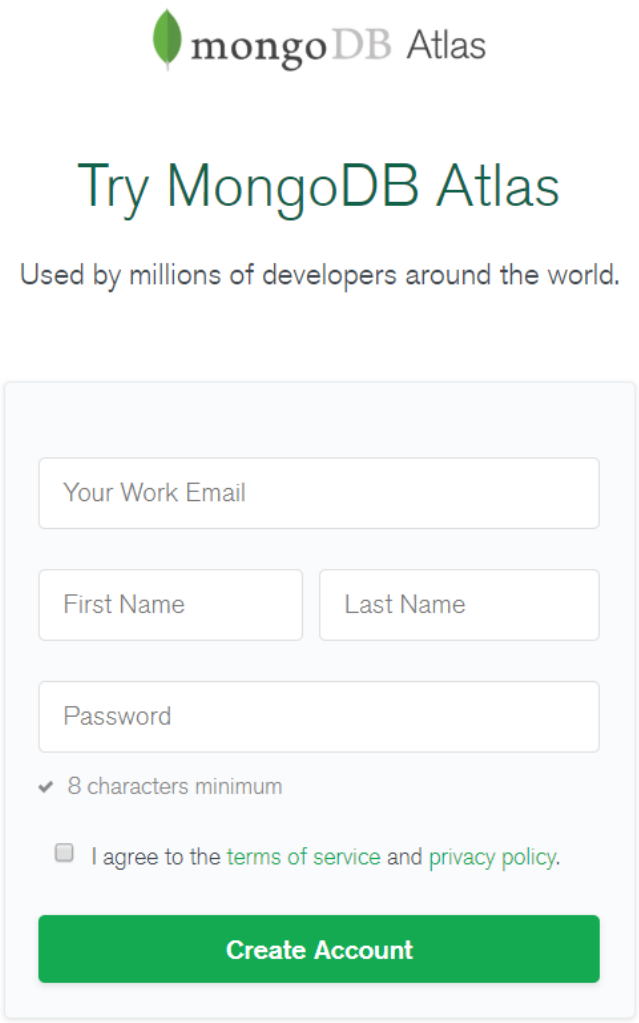

Feito isso, prosseguiremos com a configuração.

Na tela seguinte, podemos escolher a opção gratuita e após isso, teremos que escolher uma Cloud Provider. Amazon, Google e Azure são as opções que temos disponíveis. Pode-se escolher qualquer uma delas. Nessa atividade, irei utilizar a Cloud da Amazon. A região fica a seu critério.

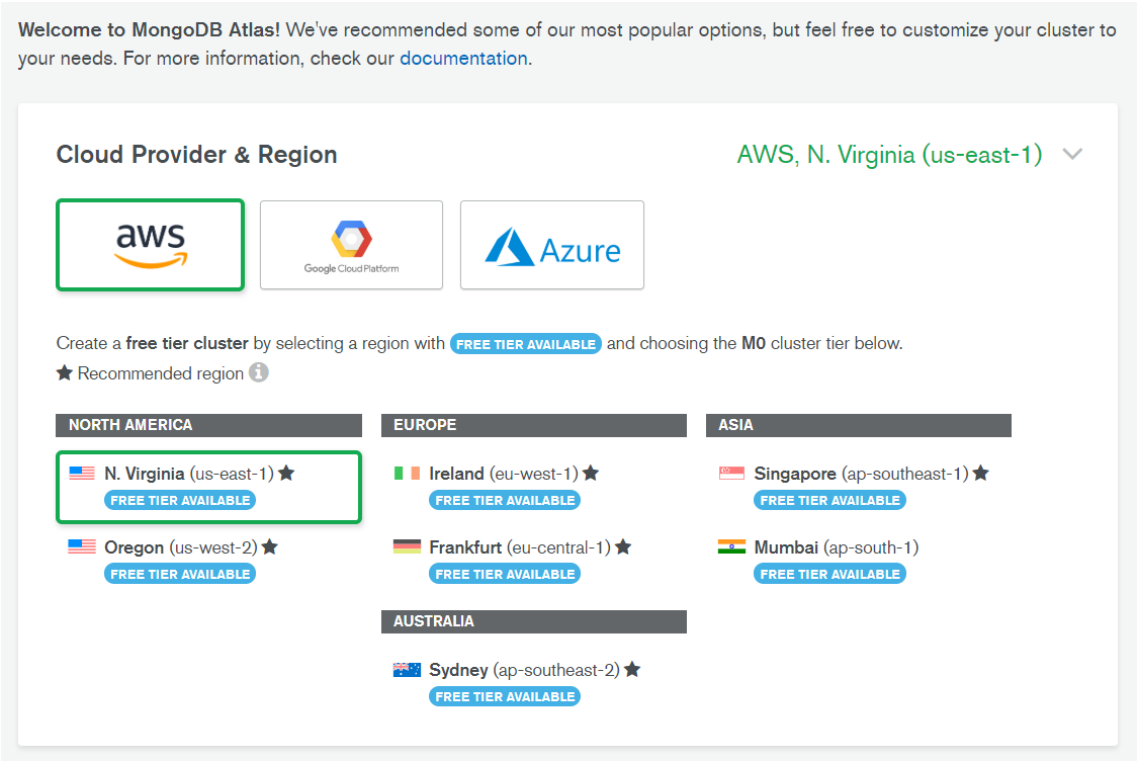

Clicando em “Create Cluster” na parte inferior, teremos concluído essa fase inicial de definição de ferramentas de trabalho. Em seguida, somos redirecionados para a interface demonstrada na figura abaixo, onde iniciaremos nosso trabalho no MongoDB:

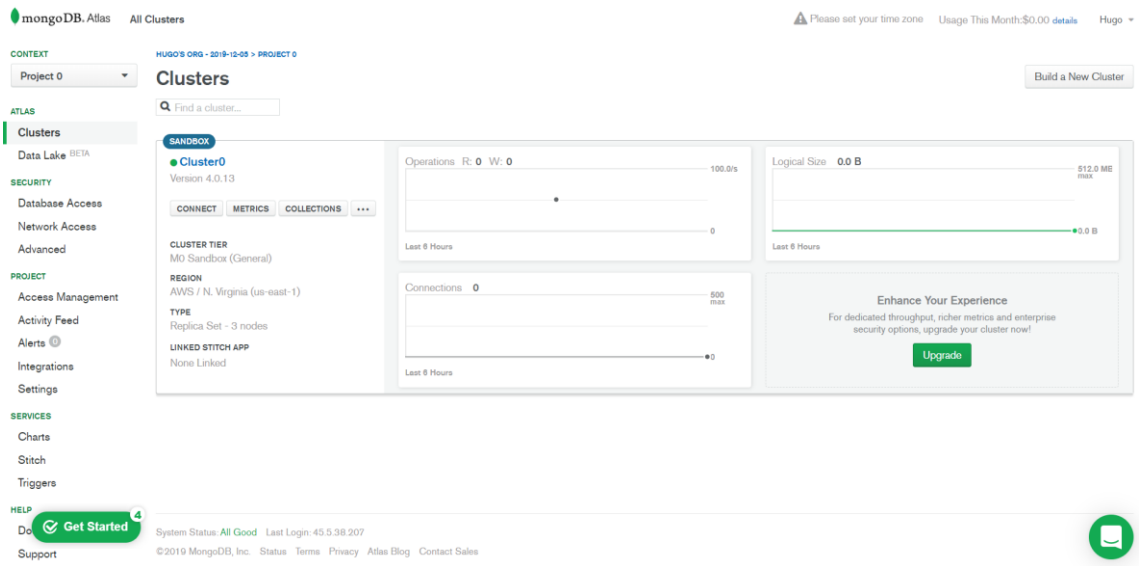

O próximo passo é criarmos nosso usuário e senha para acessar a cluster:

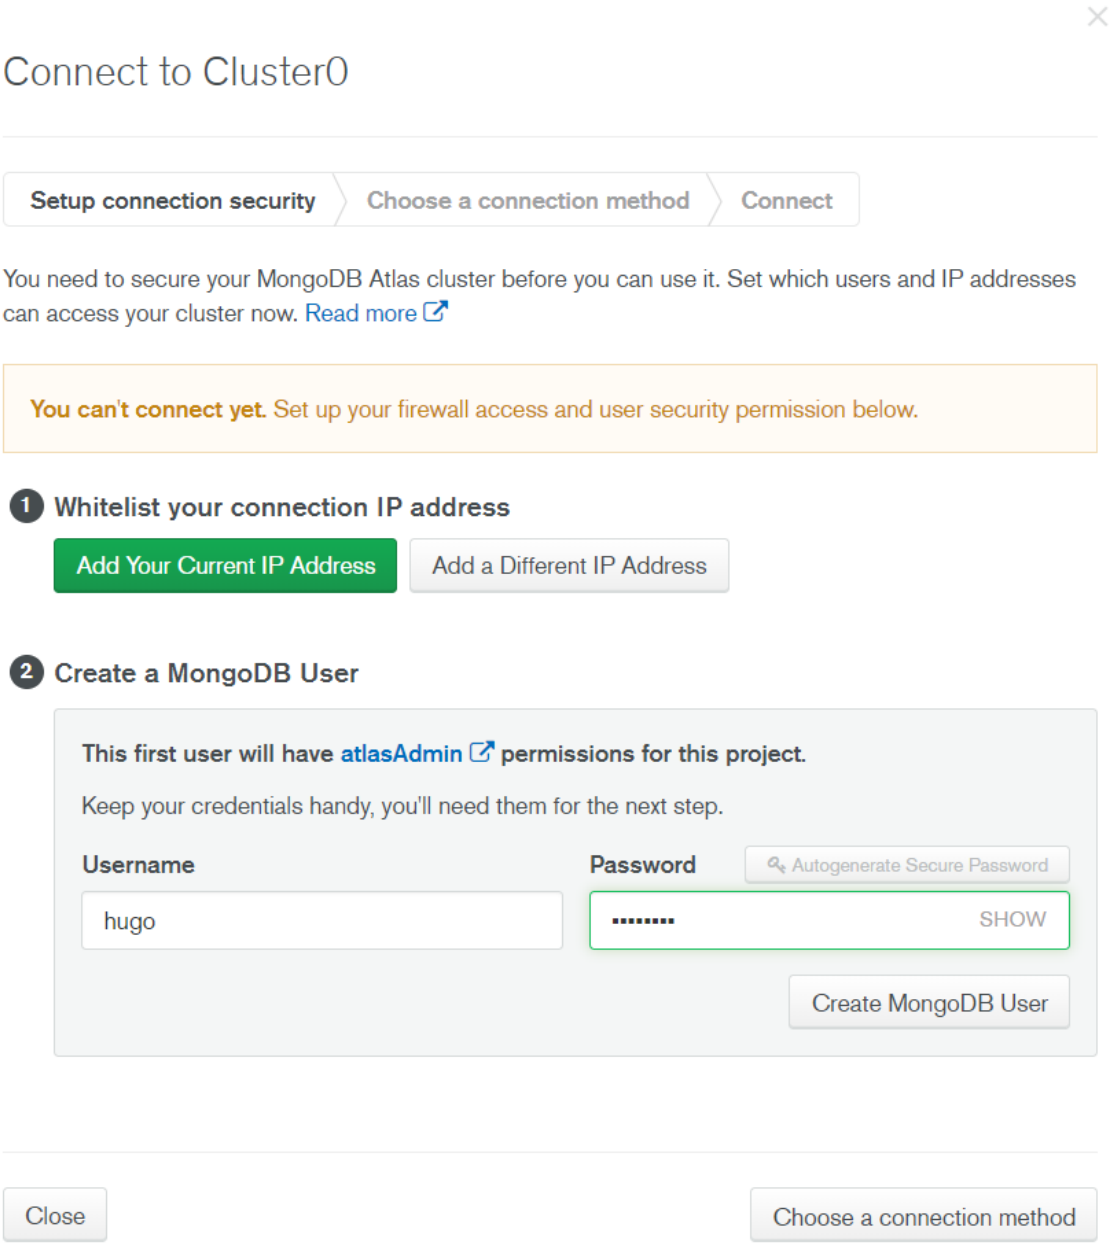

Escolher o método de conexão: "Connect your application". E em seguida, acessar e salvar a sua string para conexão.

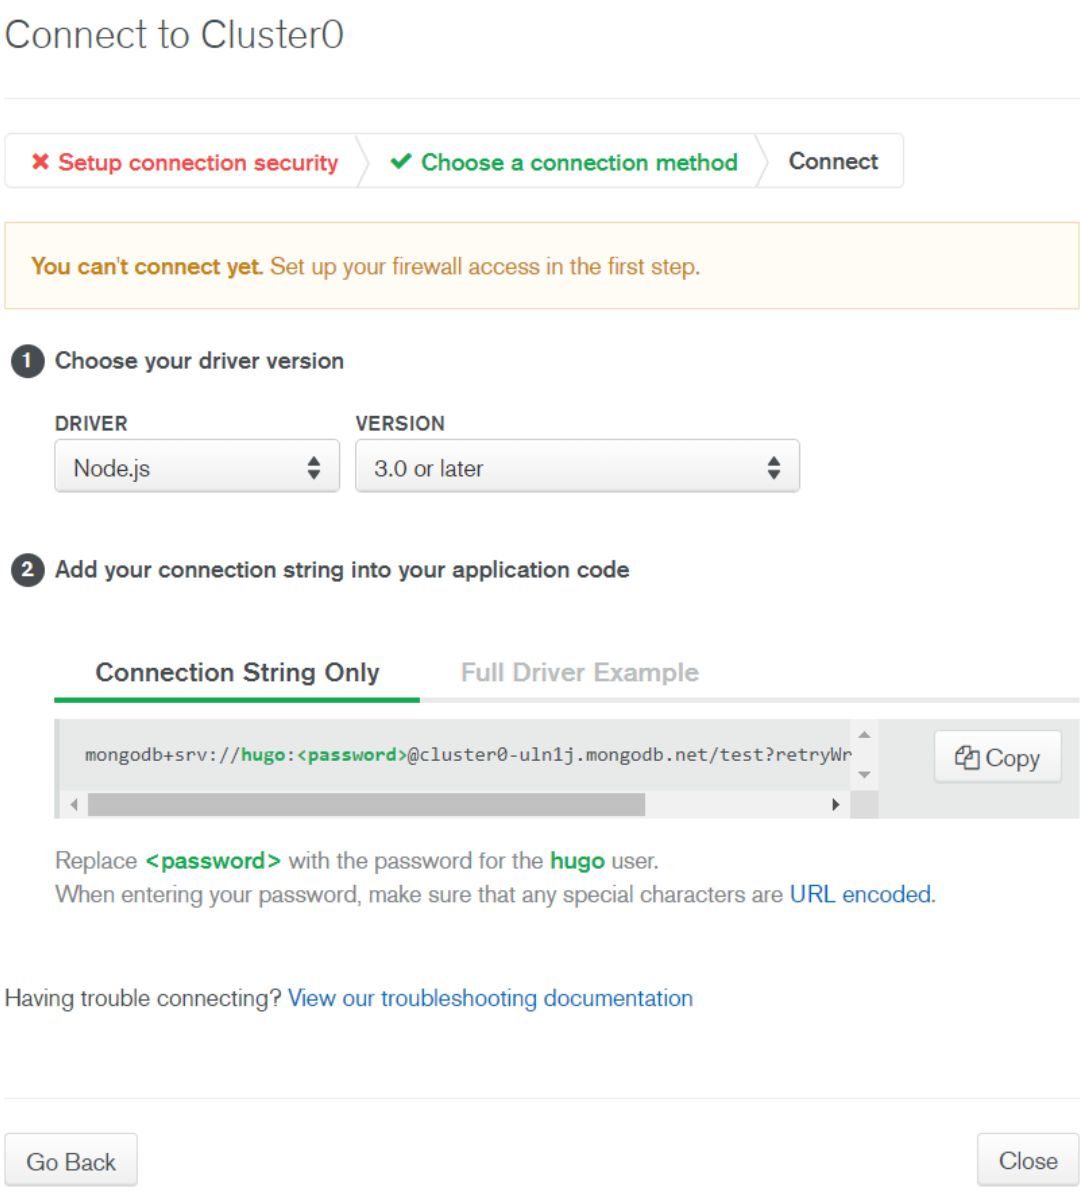

Agora vamos configurar no menu security o acesso via rede.

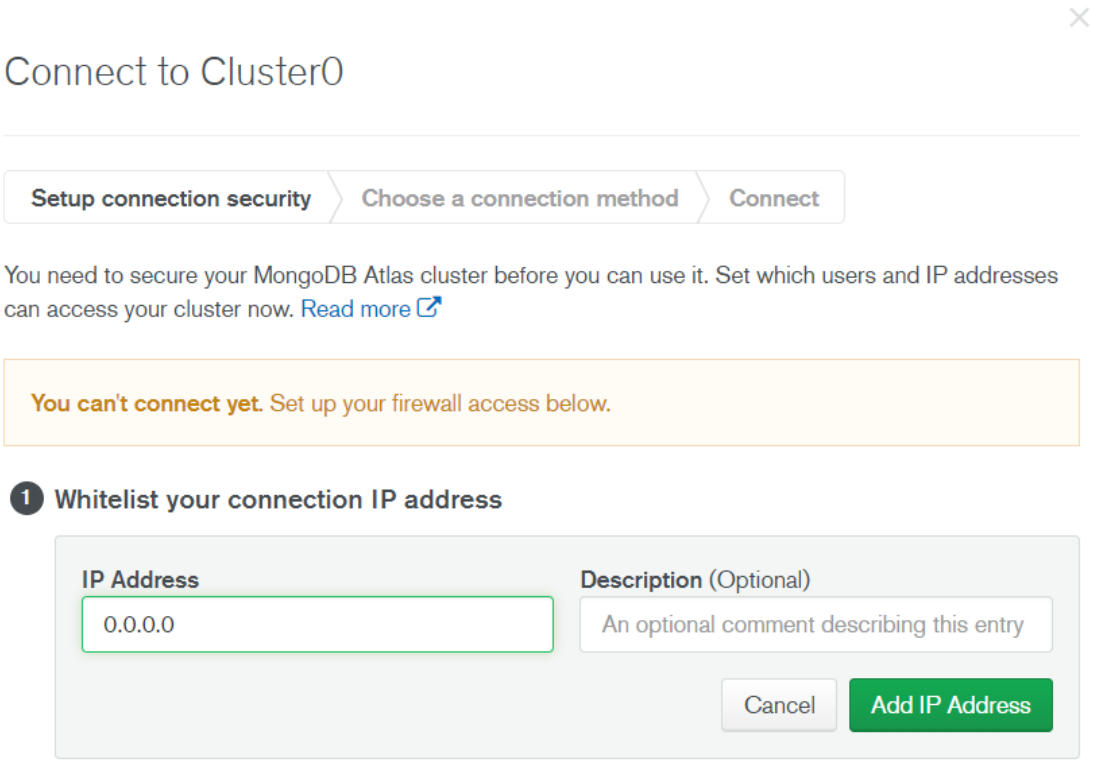

Iremos utilizar o IP 0.0.0.0 na configuração. Porque assim, possibilitaremos o acesso ao banco de dados a partir de qualquer máquina. E assim finalizamos nosso 1º passo.

2º passo: Criar a conexão com o atlas

Iremos importar as bibliotecas pymongo e pandas para poder dar continuidade no projeto.

Atribuímos à variável **myclient** a string de acesso que foi gerada pelo Atlas.

Logo após isso, na guia de “Collections” criaremos nossa base de dados e daremos nome à ela de **ovni** e a coleção de **ovnis**. Como mostra a figura a seguir:

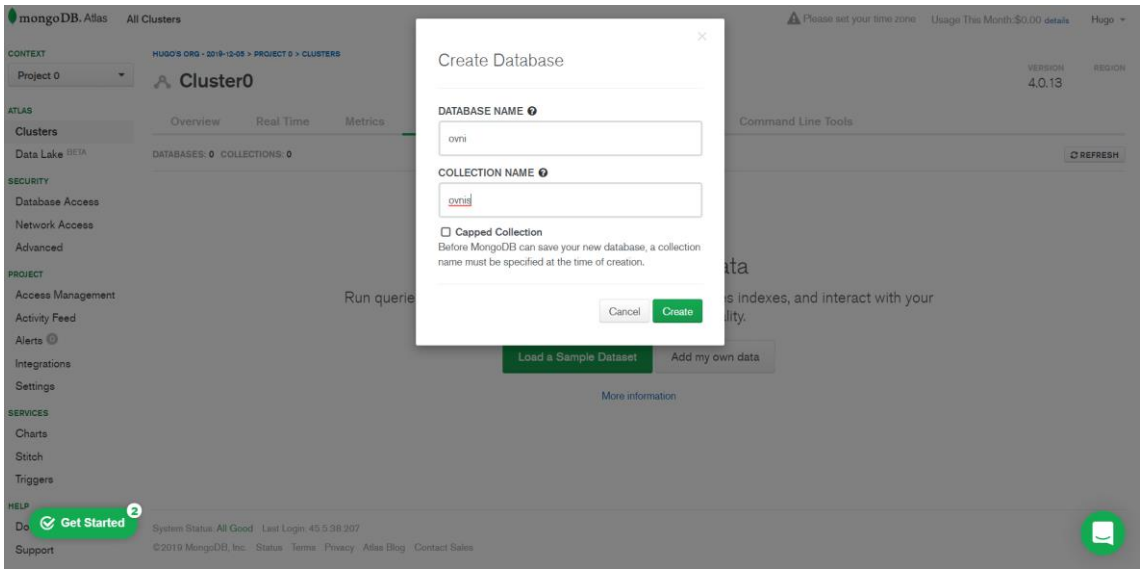

Feito isso, iremos para o próximo passo.

3º passo: Inserir na coleção criada todos os registros do df_OVNI_preparado.

A primeira parte consiste em ler nosso data frame e converte-lo em um json.

Para isso, precisaremos primeiramente importar a biblioteca **json** e logo após ler e converter o data frame. Como mostra a figura a seguir:

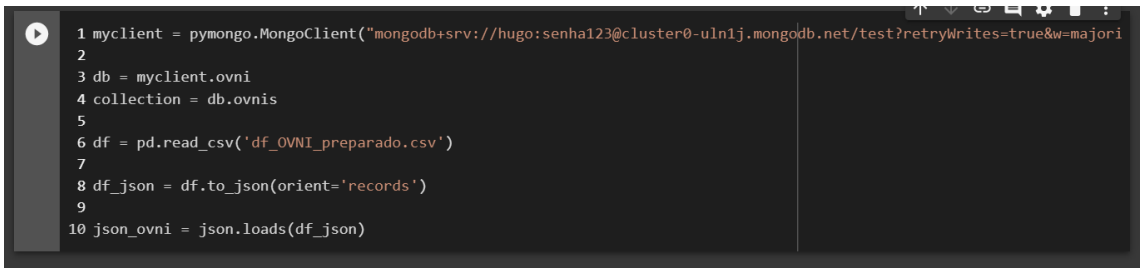

```
1 myclient = pymongo.MongoClient("mongodb+srv://hugo:senha123@cluster0-uln1j.mongodb.net/test?retryWrites=true&w=majori
2
3 db = myclient.ovni
4 collection = db.ovnis
5
6 df = pd.read_csv('df_OVNI_preparado.csv')
7
8 df_json = df.to_json(orient='records')
9
10 json_ovni = json.loads(df_json)
```

Na variável **df** nós lemos o data frame e ao final do procedimento de conversão, temos a variável **json_ovni** com o nosso data frame convertido em json.

Agora iremos inserir nosso json no banco de dados.

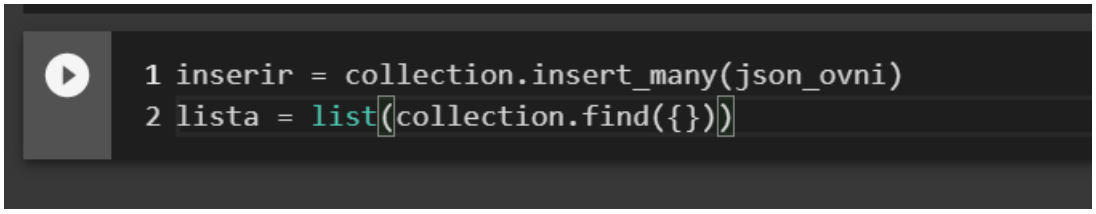

```
1 inserir = collection.insert_many(json_ovni)
2 lista = list(collection.find({}))
```

Podemos notar que no nosso banco já aparecem os dados inseridos, como mostra a figura a seguir:

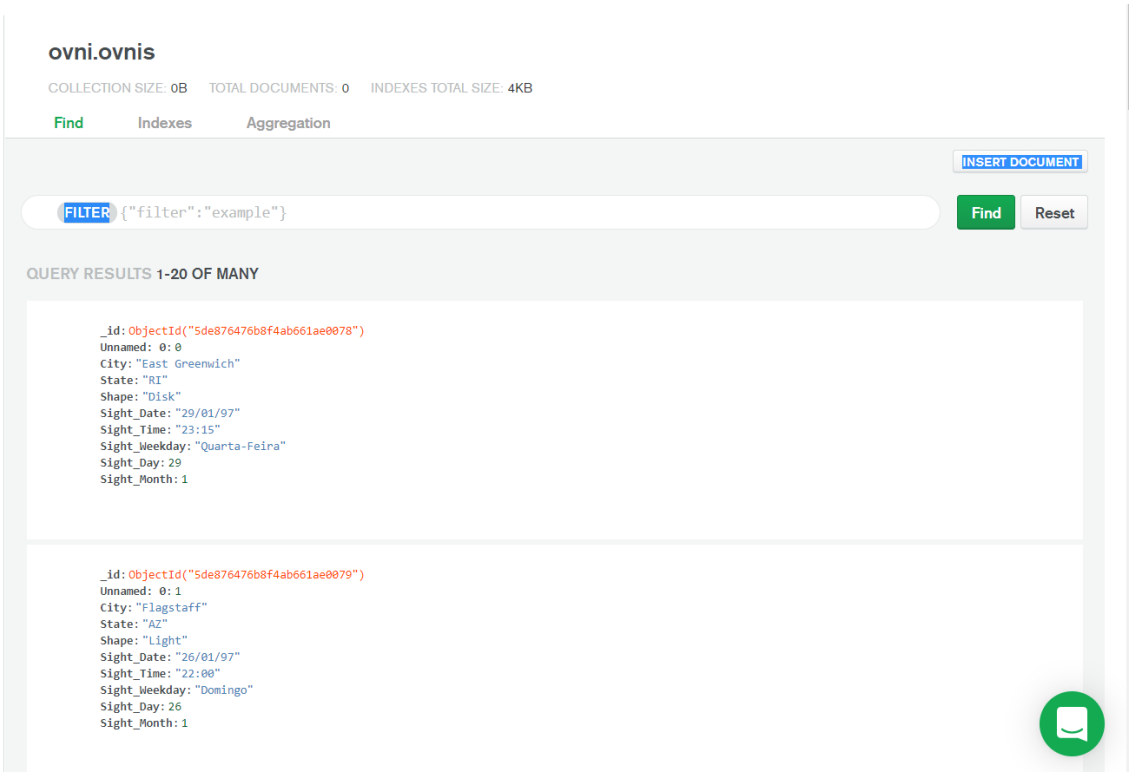

4º passo: Contar e mostrar quantos documentos há na coleção ovnis.

Nesse passo iremos contar e mostrar quantos documento há na coleção **ovnis**.

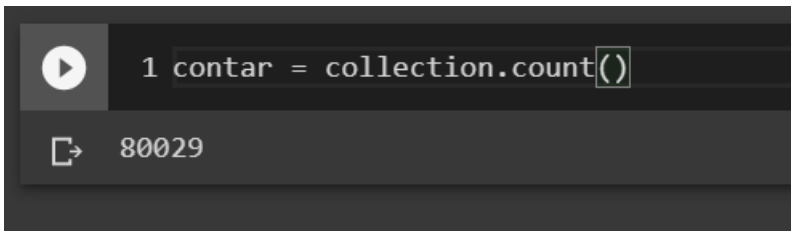

Utilizamos a função **count()** para poder contar e em seguida temos a saída esperada, como mostra a figura acima.

5º passo: Resgatar todos os documentos (registros) da coleção ovnis e ordenar por tipo (shape).

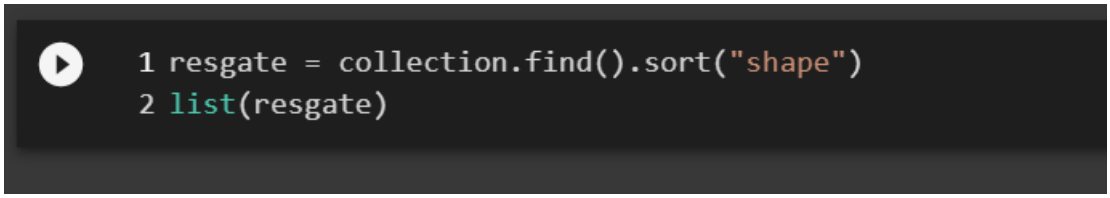

Para resgatar e ordenar os documentos, utilizamos as funções **find()** e com a função **sort()** passamos o parâmetro desejado, que no nosso caso é o **shape**. E assim, obtemos o seguinte resultado:


```
[{'City': 'East Greenwich',
  'Shape': 'Disk',
  'Sight_Date': '29/01/97',
  'Sight_Day': 29,
  'Sight_Month': 1,
  'Sight_Time': '23:15',
  'Sight_Weekday': 'Quarta-Feira',
  'State': 'RI',
  'Unnamed: 0': 0,
  '_id': ObjectId('5de876476b8f4ab661ae0078')},
 {'City': 'Flagstaff',
  'Shape': 'Light',
  'Sight_Date': '26/01/97',
  'Sight_Day': 26,
  'Sight_Month': 1,
  'Sight_Time': '22:00',
  'Sight_Weekday': 'Domingo',
  'State': 'AZ',
  'Unnamed: 0': 1,
  '_id': ObjectId('5de876476b8f4ab661ae0079')},
 {'City': 'Marion',
  'Shape': 'Triangle',
  'Sight_Date': '25/01/97',
  'Sight_Day': 25,
  'Sight_Month': 1,
  'Sight_Time': '21:00',
  'Sight_Weekday': 'Sábado',
  'State': 'WI',
  'Unnamed: 0': 2,
  '_id': ObjectId('5de876476b8f4ab661ae007a')},
 {'City': 'Alta',
  'Shape': 'Other',
  'Sight_Date': '24/01/97',
```


6º passo: Verificar quantas ocorrências existem por estado.

Nessa etapa iremos verificar quantas ocorrências existem por estado.

```
ocorrencia = list(collection.aggregate([{'$group': {'Views': {'$sum': 1},
'_id': '$State'}}, {'$sort': {'views': -1}}]))
```

E assim, obtemos o seguinte resultado:

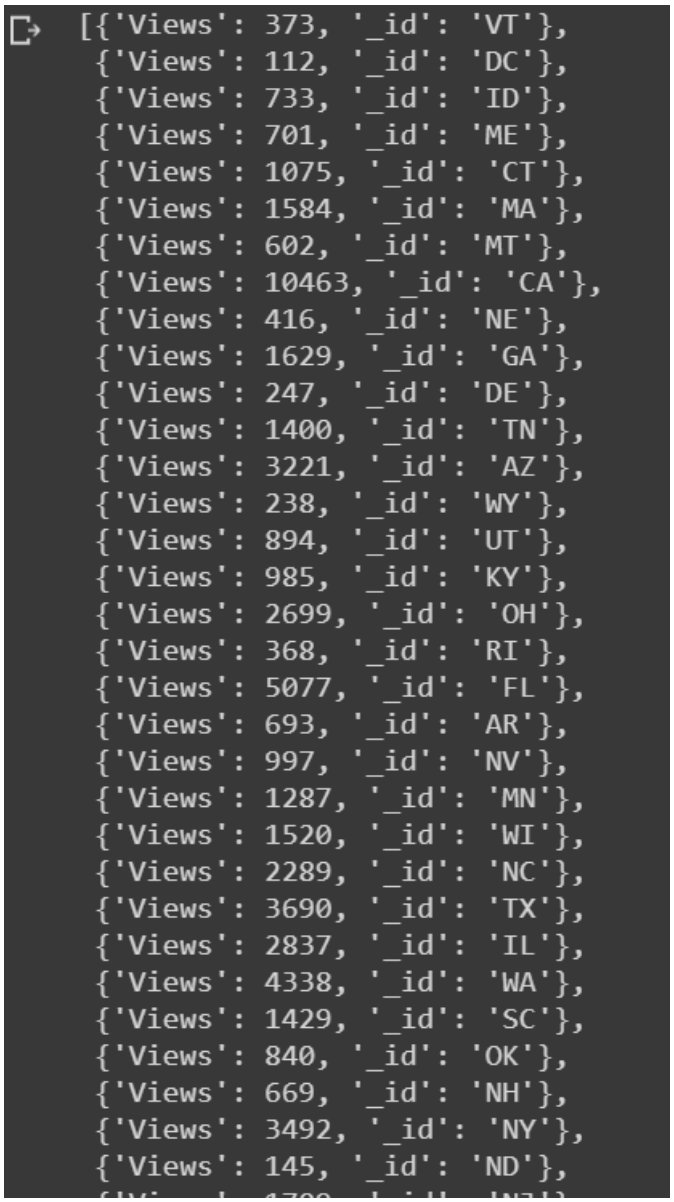

```
[{'Views': 373, '_id': 'VT'},
 {'Views': 112, '_id': 'DC'},
 {'Views': 733, '_id': 'ID'},
 {'Views': 701, '_id': 'ME'},
 {'Views': 1075, '_id': 'CT'},
 {'Views': 1584, '_id': 'MA'},
 {'Views': 602, '_id': 'MT'},
 {'Views': 10463, '_id': 'CA'},
 {'Views': 416, '_id': 'NE'},
 {'Views': 1629, '_id': 'GA'},
 {'Views': 247, '_id': 'DE'},
 {'Views': 1400, '_id': 'TN'},
 {'Views': 3221, '_id': 'AZ'},
 {'Views': 238, '_id': 'WY'},
 {'Views': 894, '_id': 'UT'},
 {'Views': 985, '_id': 'KY'},
 {'Views': 2699, '_id': 'OH'},
 {'Views': 368, '_id': 'RI'},
 {'Views': 5077, '_id': 'FL'},
 {'Views': 693, '_id': 'AR'},
 {'Views': 997, '_id': 'NV'},
 {'Views': 1287, '_id': 'MN'},
 {'Views': 1520, '_id': 'WI'},
 {'Views': 2289, '_id': 'NC'},
 {'Views': 3690, '_id': 'TX'},
 {'Views': 2837, '_id': 'IL'},
 {'Views': 4338, '_id': 'WA'},
 {'Views': 1429, '_id': 'SC'},
 {'Views': 840, '_id': 'OK'},
 {'Views': 669, '_id': 'NH'},
 {'Views': 3492, '_id': 'NY'},
 {'Views': 145, '_id': 'ND'},
```

7º passo: Buscar todas as ocorrências da cidade Phoenix.

Agora iremos buscar as ocorrências da cidade de Phonex.

```
1 phoenix = list(collection.find({'City' : 'Phoenix'}))
```

Desta forma podemos obter as ocorrências desejadas, na figura abaixo temos o resultado obtido:

```
[{'City': 'Phoenix',
  'Shape': 'Chevron',
  'Sight_Date': '01/01/97',
  'Sight_Day': 1,
  'Sight_Month': 1,
  'Sight_Time': '19:30',
  'Sight_Weekday': 'Quarta-Feira',
  'State': 'AZ',
  'Unnamed: 0': 36,
  '_id': ObjectId('5de876476b8f4ab661ae009c')},
 {'City': 'Phoenix',
  'Shape': 'Cigar',
  'Sight_Date': '11/02/97',
  'Sight_Day': 11,
  'Sight_Month': 2,
  'Sight_Time': '11:00',
  'Sight_Weekday': 'Domingo',
  'State': 'AZ',
  'Unnamed: 0': 57,
  '_id': ObjectId('5de876476b8f4ab661ae00b1')},
 {'City': 'Phoenix',
  'Shape': 'Other',
  'Sight_Date': '20/03/97',
  'Sight_Day': 20,
  'Sight_Month': 3,
  'Sight_Time': '00:00',
  'Sight_Weekday': 'Quinta-Feira',
  'State': 'AZ',
  'Unnamed: 0': 99,
  '_id': ObjectId('5de876476b8f4ab661ae00db')},
 {'City': 'Phoenix',
  'Shape': 'Light',
  'Sight_Date': '17/03/97',
  'Sight_Day': 17,
```

8º passo: Buscar as ocorrências do estado da Califórnia e ocultar o id de cada documento (registro)

Chegamos no nosso 8º e último passo dessa atividade, agora nós iremos Buscar as ocorrências do estado da Califórnia e ocultar o id de cada documento (registro).

```
1 cali = list(collection.find({'City' : 'Phoenix'}, {'_id': 0}))
```

Da mesma forma do passo anterior podemos fazer a busca de ocorrências do estado, a única diferença é que agora podemos utilizar o número 0 como parâmetro para ocultar o ID. E assim finalizamos nossa atividade.

GITHUB

https://github.com/HugoCalisto/datascience/